SPP-Net 论文详解

SPP-Net 是出自 2015 年发表在 IEEE 上的论文-《Spatial Pyramid Pooling in Deep ConvolutionalNetworks for Visual Recognition》。

在此之前，所有的神经网络都是需要输入固定尺寸的图片，比如 224*224（ImageNet）、32*32(LenNet)、96*96 等。这样对于我们希望检测各种大小的图片的时候，需要经过 crop，或者 warp 等一系列操作，这都在一定程度上导致图片信息的丢失和变形，限制了识别精确度。而且，从生理学角度出发，人眼看到一个图片时，大脑会首先认为这是一个整体，而不会进行 crop 和 warp，所以更有可能的是，我们的大脑通过搜集一些浅层的信息，在更深层才识别出这些任意形状的目标。

为什么要固定输入图片的大小？

卷积层的参数和输入大小无关，它仅仅是一个卷积核在图像上滑动，不管输入图像多大都没关系，只是对不同大小的图片卷积出不同大小的特征图，但是全连接层的参数就和输入图像大小有关，因为它要把输入的所有像素点连接起来,需要指定输入层神经元个数和输出层神经元个数，所以需要规定输入的 feature 的大小。

因此，固定长度的约束仅限于全连接层。以下图为例说明：

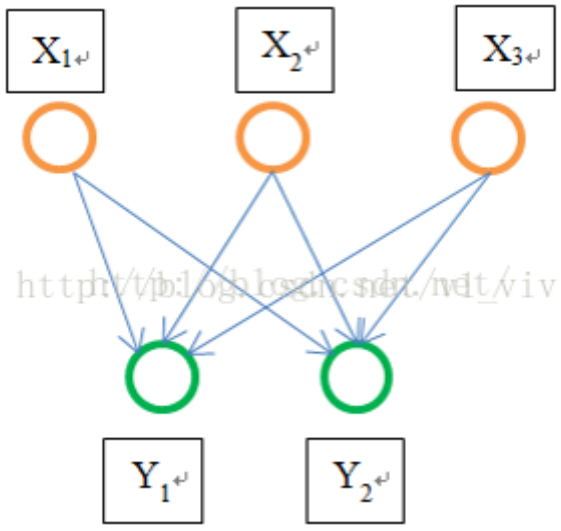

作为全连接层，如果输入的 x 维数不等，那么参数 w 肯定也会不同，因此，全连接层是必须确定输入，输出个数的。

SPP-Net 是如何调整网络结构的？

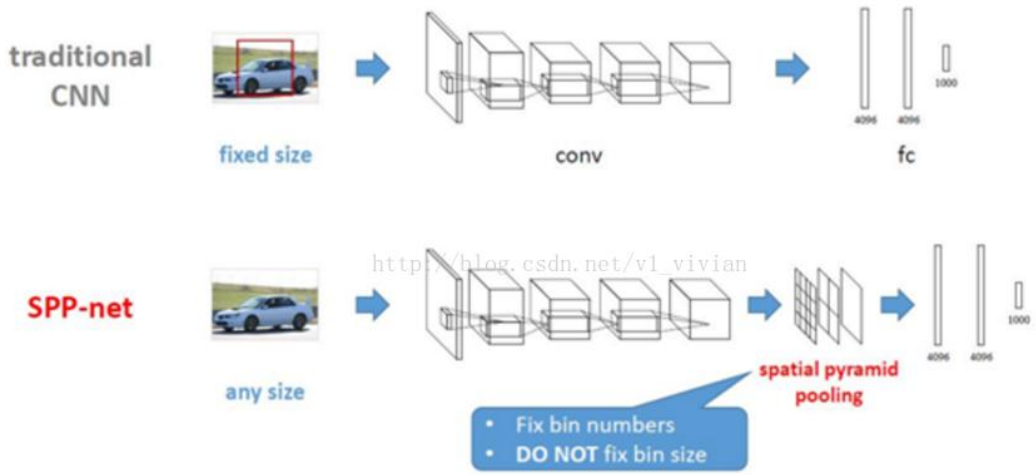

SPP-Net 在最后一个卷积层后，接入了金字塔池化层，使用这种方式，可以让网络输入任意的图片，而且还会生成固定大小的输出。

什么是金字塔池化？

以下图为例进行解释说明：

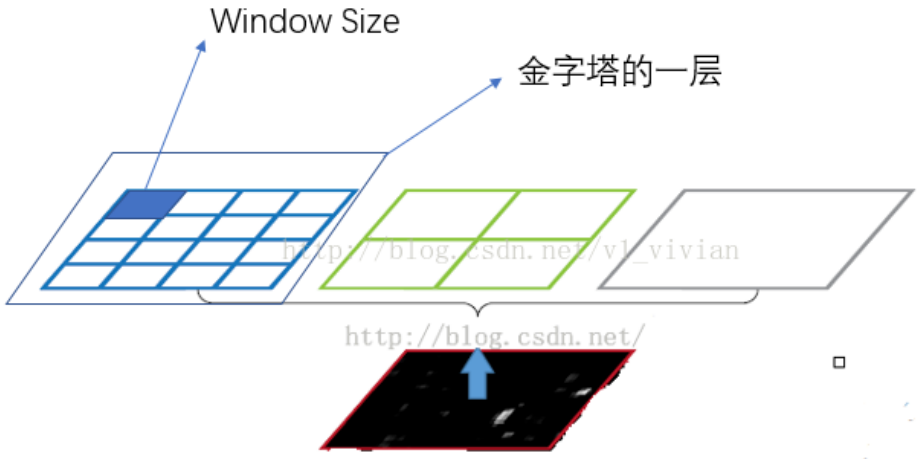

黑色图片代表卷积之后的特征图，接着我们以不同大小的块来提取特征，分别是 4*4，2*2，1*1，将这三张网格放到下面这张特征图上，就可以得到 16+4+1=21 种不同的块(Spatial bins)，我们从这 21 个块中，每个块提取出一个特征，这样刚好就是我们要提取的 21 维特征向量。这种以不同的大小格子的组合方式来池化的过程就是空间金字塔池化（SPP）。比如，要进行空间金字塔最大池化，其实就是从这 21 个图片块中，分别计算每个块的最大值，从而得到一个输出单元，最终得到一个 21 维特征的输出。

从整体过程来看，就是如下图所示：

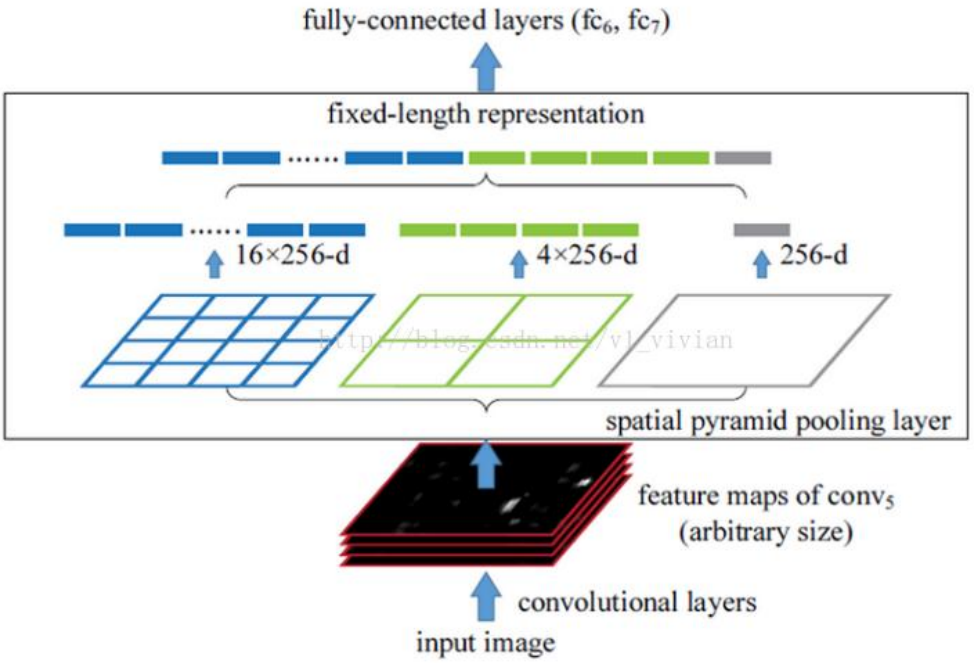

输出向量大小为 Mk， M=#bins， k=#filters，作为全连接层的输入。

例如上图，所以 Conv5 计算出的 feature map 也是任意大小的，现在经过 SPP 之后，就可以变成固定大小的输出了，以上图为例，一共可以输出（16+4+1）*256 的特征。

金字塔池化的意义是什么？

总结而言，当网络输入的是一张任意大小的图片，这个时候我们可以一直进行卷积、池化，直到网络的倒数几层的时候，也就是我们即将与全连接层连接的时候，就要使用金字塔池化，使得任意大小的特征图都能够转换成固定大小的特征向量，这就是空间金字塔池化的意义（多尺度特征提取出固定大小的特征向量）。

网络训练阶段：

论文中将网络的训练分为两种：一种是 single-size,一种是 Multi-size。

先讲解 single-size 的训练过程：

理论上说，SPP-net 支持直接以多尺度的原始图片作为输入后直接 BP 即可。实际上，caffe 等实现中，为了计算的方便，GPU,CUDA 等比较适合固定尺寸的输入，所以训练的时候输入是固定了尺度了的。以 224*224 的输入为例：

在 conv5 之后的特征图为：13x13（a*a）
金字塔层 bins:　n*n
将 pooling 层作为 sliding window pooling。
windows_size=[a/n] 向上取整 ， stride_size=[a/n]向下取整。

例如论文中给出的参数如下：

```
[pool3x3]
type=pool
pool=max
inputs=conv5
sizeX=5
stride=4

[pool2x2]
type=pool
pool=max
inputs=conv5
sizeX=7
stride=6

[pool1x1]
type=pool
pool=max
inputs=conv5
sizeX=13
stride=13
```



```
[fc6]
type=fc
outputs=4096
inputs=pool3x3,pool2x2,pool1x1
```

对于 pool 3*3:　　sizeX=5 的计算公式是：[13/3]向上取整=5 ，stride = 4 的计算公式是：[13/3]向下取整。

如果输入改成 180x180，这时候 conv5 出来的 reponse map 为 10x10，类似的方法，能够得到新的 pooling 参数。

对于 Multi-size training 即就是：使用两个尺度进行训练：224*224 和 180*180

训练的时候，224x224 的图片通过 crop 得到，180x180 的图片通过缩放 224x224 的图片得到。之后，迭代训练，即用 224 的图片训练一个 epoch，之后 180 的图片训练一个 epoch，交替地进行。

两种尺度下，在 SSP 后，输出的特征维度都是(9+4+1)x256，参数是共享的，之后接全连接层即可。

论文中说，这样训练的好处是可以更快的收敛。

网络测试阶段

输入为任意大小的图片

SPP-Net 与 R-CNN 的对比

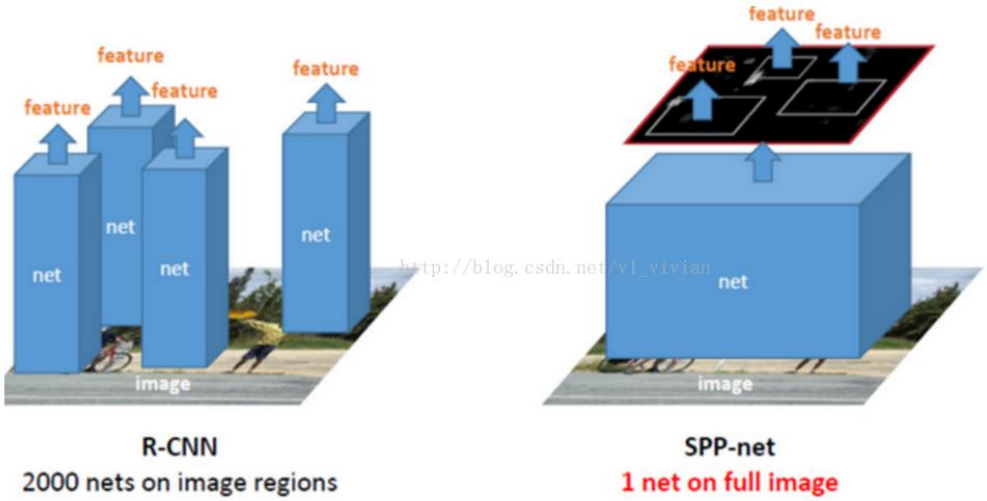

对于 R-CNN，整个过程是：

首先通过选择性搜索，对待检测的图片进行搜索出~2000 个候选窗口。
把这 2k 个候选窗口的图片都缩放到 227*227，然后分别输入 CNN 中，每个 proposal 提取出一个特征向量，也就是说利用 CNN 对每个 proposal 进行提取特征向量。
把上面每个候选窗口的对应特征向量，利用 SVM 算法进行分类识别。

可以看出 R-CNN 的计算量是非常大的，因为 2k 个候选窗口都要输入到 CNN 中，分别进行特征提取。

而对于 SPP-Net，整个过程是：

首先通过选择性搜索，对待检测的图片进行搜索出 2000 个候选窗口。这一步和 R-CNN 一样。
特征提取阶段。这一步就是和 R-CNN 最大的区别了，这一步骤的具体操作如下：把整张待检测的图片，输入 CNN 中，进行一次性特征提取，得到 feature maps，然后在 feature maps 中找到各个候选框的区域，再对各个候选框采用金字塔空间池化，提取出固定长度的特征向量。而 R-CNN 输入的是每个候选框，然后在进入 CNN，因为 SPP-Net 只需要一次对整张图片进行特征提取，速度会大大提升。
最后一步也是和 R-CNN 一样，采用 SVM 算法进行特征向量分类识别。

Mapping a Window to Feature Maps
我们知道，在原图中的 proposal,经过多层卷积之后，位置还是相对于原图不变的（如下图所示），那现在需要解决的问题就是，如何能够将原图上的 proposal,映射到卷积之后得到的特征图上，因为在此之后我们要对 proposal 进行金字塔池化。

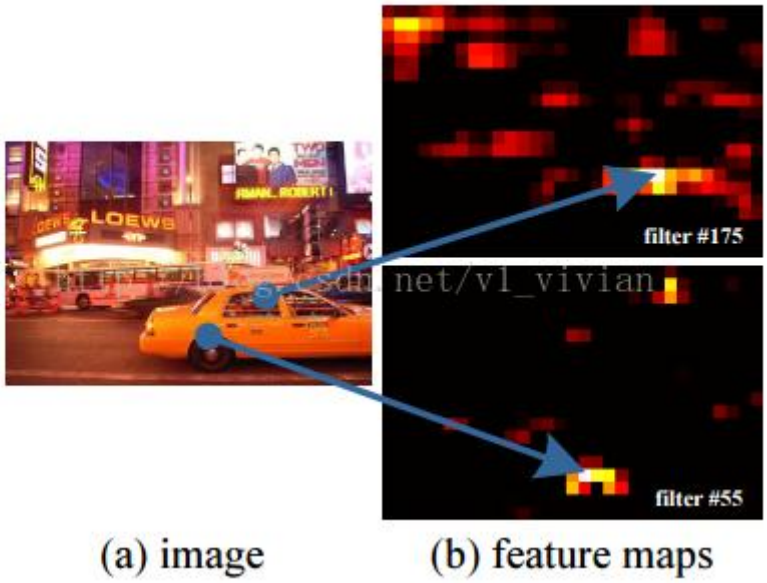

对于映射关系，论文中给出了一个公式：

假设(x’,y’)表示特征图上的坐标点，坐标点(x,y)表示原输入图片上的点，那么它们之间有如下转换关系，这种映射关心与网络结构有关： (x,y)=(S*x’,S*y’)

反过来，我们希望通过(x,y)坐标求解(x’,y’)，那么计算公式如下：

其中 S 就是 CNN 中所有的 strides 的乘积，包含了池化、卷积的 stride。

比如，对于下图的集中网络结构，S 的计算如下：

model	conv1	conv2	conv3	conv4	conv5	conv6	conv7
ZF-5	96×7^2, str 2 LRN, pool 3^2, str 2 map size 55×55	256×5^2, str 2 LRN, pool 3^2, str 2 27×27	384×3^2 13×13	384×3^2 13×13	256×3^2 13×13	-	-
Convnet*-5	96×11^2, str 4 LRN, map size 55×55	256×5^2 LRN, pool 3^2, str 2 27×27	384×3^2 pool 3^2, 2 13×13	384×3^2 13×13	256×3^2 13×13	-	-
Overfeat-5/7	96×7^2, str 2 pool 3^2, str 3, LRN map size 36×36	256×5^2 pool 2^2, str 2 18×18	512×3^2 18×18	512×3^2 18×18	512×3^2 18×18	512×3^2 18×18	512×3^2 18×18

论文中使用的是 ZF-5： S=2*2*2*2=16

Overfeat-5/7： S =2*3*2 =12

检测算法

对于检测算法，论文中是这样做到：使用 ss 生成~2k 个候选框，缩放图像 min(w,h)=s 之后提取特征，每个候选框使用一个 4 层的空间金字塔池化特征，网络使用的是 ZF-5 的 SPPNet 形式。之后将 12800d 的特征输入全连接层，SVM 的输入为全连接层的输出。

这个算法可以应用到多尺度的特征提取：先将图片 resize 到五个尺度：480，576，688，864，1200，加自己 6 个。然后在 map window to feature map 一步中，选择 ROI 框尺度在｛6 个尺度｝中大小最接近 224x224 的那个尺度下的 feature maps 中提取对应的 roi feature。这样做可以提高系统的准确率。

完整的 SPP-Net

最后，用一张图来完整的描述 SPP-Net。

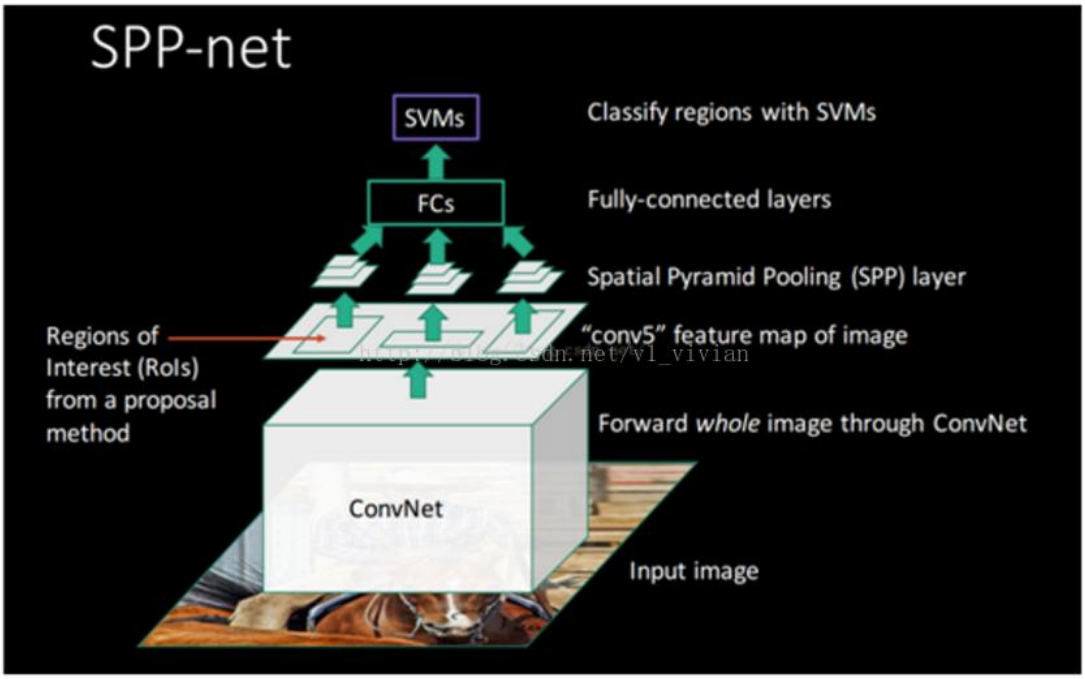

Link: https://blog.csdn.net/v1_vivian/article/details/73275259